



Prédictions IA pour les JO Paris 2024

Système Neurolympics avec XGBoost V3 Ultra-Réaliste

Groupe 8 : Ilyas, Boubaker, Theo

Intelligence Artificielle appliquée aux prédictions olympiques



Contexte et Objectifs



Médailles France

Combien de médailles gagnera la France en tant que pays hôte ?



Classement Mondial

Quel sera le classement des 25 premiers pays aux JO 2024 ?



Athlètes Prometteurs

Quels athlètes ont les meilleures chances de remporter des médailles ?

Notre approche combine le Machine Learning avec des données historiques olympiques couvrant 125 ans (1896-2021) et les profils des athlètes qualifiés pour 2024. L'innovation clé : un feature engineering sophistiqué intégrant le nombre d'athlètes qualifiés par pays et par sport.



Datasets et Volume de Données

1

olympic_results.html

260,458 entrées - Format HTML

Résultats historiques complets de 1896 à 2021, incluant tous les sports et disciplines olympiques

2

olympic_athletes.json

75,904 profils - Format JSON

Profils détaillés des athlètes avec biographies, performances et statistiques complètes

3

olympic_medals.xlsx

21,697 médailles - Format Excel

Détails des médailles par événement, pays, sport et type de récompense

4

paris2024_athletes.csv

11,110 athlètes - Format CSV

Athlètes qualifiés pour Paris 2024 avec délégations et spécialités

Volume total : 369,000+ entrées analysées | 122 pays représentés | 45 sports olympiques | 125 ans d'histoire

Problèmes de Qualité des Données

Défis Majeurs Identifiés

Types médailles incohérents

Variations multiples : 'GOLD', 'Gold', 'Team Gold', valeurs nulles

15% d'entrées invalides

Noms de pays multiples

'United States' vs 'United States of America' vs 'USA' - nécessite normalisation

Données manquantes

25% des athlètes sans année de naissance, 12% sans nom complet

Formats de dates incohérents

Multiples formats détectés : 'YYYY-MM-DD', 'DD/MM/YYYY', 'YYYY'

Problèmes d'encodage

Caractères spéciaux et accents provoquant des crashes système

45 erreurs par heure



Pipeline de Nettoyage Automatisé



Validation

Détection automatique des problèmes de qualité et anomalies dans les données



Normalisation

Mapping pays unifié : 156 variations réduites à 122 codes uniques standardisés




Filtrage

Sélection stricte des médailles valides uniquement pour garantir la fiabilité



Imputation

Remplissage intelligent des données manquantes basé sur les moyennes par sport



Encodage

Conversion UTF-8 complète avec gestion avancée des caractères spéciaux

89%

Qualité Finale

Amélioration significative par rapport à 67% initialement

0

Erreurs Encodage

Élimination complète vs 45 erreurs par heure auparavant

252K

Entrées Propres

Données validées et prêtes pour l'entraînement IA

Architecture Technique Complète



Modèles IA

- **XGBoost V3** - Modèle principal avec ROC-AUC 90.6%
- **CatBoost V2** - Alternative avec ordered boosting avancé
- **Random Forest V2** - Baseline pour comparaison



Données

- **PostgreSQL** - Base centralisée avec 369K entrées
- **Pipeline ETL** - Nettoyage et validation automatisés
- **Cache** - Optimisation des performances



WebApp + API

- **Flask Backend** - 8 endpoints API RESTful
- **Bootstrap 5** - Interface utilisateur moderne
- **Plotly.js** - Graphiques interactifs dynamiques





Évolution des Modèles IA

1

M1 - Random Forest

34 médailles France

Boost simple 1.25x | Performance baseline établie

2

M2 - Catboost

28 médailles France

Ordered boosting

3

M3 - XGBoost

58 médailles France

Feature engineering + calibration | Bond de +71%

Progression Technique

- **Algorithme** : Random Forest → [XGBoost \(250 arbres\)](#)
- **Features** : 7 variables de base → [12 features avancées](#)
- **Innovation clé** : Intégration du nombre d'athlètes qualifiés 2024 par pays et sport

Impact Mesurable

Le passage à XGBoost V3 avec feature engineering sophistiqué a permis une amélioration de **71%** [des prédictions](#) par rapport à la version initiale, démontrant l'efficacité de notre approche méthodologique.

XGBoost V3 – Innovations Révolutionnaires



Feature Engineering Avancé

Création de **athlete_count** et **expected_medals_from_athletes** - deux features basées sur les athlètes qualifiés par pays/sport pour 2024. Impact majeur : 23.4% d'importance dans le modèle.



Architecture Optimisée

Configuration fine : 250 arbres de décision, profondeur maximale 7, learning rate 0.05. Régularisation L1/L2 pour prévenir l'overfitting et garantir la généralisation.



Calibration Intelligente

Ajustement dynamique des probabilités basé sur la taille des délégations nationales. Plus d'athlètes qualifiés = boost proportionnel des chances de médailles.



Mode Ultra-Rapide

Résultats pré-calculés (seulement 8.6KB) permettant des prédictions instantanées dans la WebApp sans recalcul, améliorant drastiquement l'expérience utilisateur.

Feature Engineering Détaillé

Features Historiques (7)

- **total_medals_hist**
Médailles totales avec pondération temporelle décroissante
- **gold/silver/bronze_count**
Distribution détaillée par type de médaille
- **medals_in_sport**
Performance historique par sport et par pays
- **discipline_enc / country_enc**
Encodages catégoriels optimisés

Nouvelles Features V3 (5) ★

athlete_count
Nombre d'athlètes qualifiés 2024 par pays/sport

expected_medals_from_athletes
Médailles attendues basées sur corrélation historique

unique_medalists_hist
Nombre d'athlètes médaillés uniques historiquement

medal_per_athlete_ratio
Ratio d'efficacité médailles/athlètes par pays


medalists_in_sport_hist
Historique médaillés par sport et discipline

📌 **Impact décisif :** Les 5 nouvelles features de la version V3 représentent 54.5% de l'importance totale du modèle, démontrant la pertinence cruciale des données de qualification 2024.

Résultats France - Prédiction 2024

58 Médailles

Prédiction pour la France aux Jeux Olympiques de Paris 2024



Sports Forts Français

- 1. **Rowing** : 7.5 médailles
- 2. **Sailing** : 6.8 médailles
- 3. **Judo** : 5.7 médailles
- 4. **Athletics** : 5.6 médailles
- 5. **Swimming** : 5.1 médailles

Contexte Historique

La prédiction de 58 médailles s'inscrit dans une progression cohérente : France 2012 (34 médailles), France 2016 (42 médailles), avec un bonus significatif lié au statut de **pays hôte** en 2024.

TOP 25 PAYS - PARIS 2024

1. United States

Médailles: 123.5 | Athlètes: 619

2. China

Médailles: 106.2 | Athlètes: 398

3. Australia

Médailles: 87.6 | Athlètes: 475

4. Germany

Médailles: 76.4 | Athlètes: 457

5. Great Britain

Médailles: 70.2 | Athlètes: 342

6. Italy

Médailles: 62.5 | Athlètes: 397

7. France

Médailles: 58.4 | Athlètes: 600

8. Japan

Médailles: 44.8 | Athlètes: 431

9. Netherlands

Médailles: 43.1 | Athlètes: 289

10. Spain

Médailles: 35.9 | Athlètes: 401

11. Brazil

Médailles: 28.9 | Athlètes: 290

12. Canada

Médailles: 25.3 | Athlètes: 332

13. New Zealand

Médailles: 21.8 | Athlètes: 208

14. Poland

Médailles: 18.9 | Athlètes: 226

15. Korea

Médailles: 18.6 | Athlètes: 147

16. Ukraine

Médailles: 15.7 | Athlètes: 141

17. Denmark

Médailles: 13.0 | Athlètes: 131

18. Romania

Médailles: 11.8 | Athlètes: 96

19. Hungary

Médailles: 10.5 | Athlètes: 177

20. Jamaica

Médailles: 9.5 | Athlètes: 65

21. Switzerland

Médailles: 8.3 | Athlètes: 137

22. Norway

Médailles: 7.8 | Athlètes: 109

23. Kenya

Médailles: 7.3 | Athlètes: 74

24. South Africa

Médailles: 7.0 | Athlètes: 141


25. Belgium

Médailles: 6.7 | Athlètes: 177

 **Innovation méthodologique :** Notre système de calibration prend en compte la taille de la délégation pour obtenir des prédictions plus réalistes. Le **taux de réussite** représente le pourcentage de médailles obtenues par athlète qualifié, offrant une mesure de l'efficacité de chaque nation. Cette approche nuancée permet de mieux évaluer la force en profondeur de chaque pays.


Performance du Modèle XGBoost V3

Métriques Techniques



ROC-AUC

Performance exceptionnelle (seuil excellence : 80%)



Accuracy

Précision globale du modèle

Validation des Prédictions

- **Total médailles prédit** : 1,044 (vs ~1,000 historique moyen)
- **Dataset validation** : 5,468 médaillés vs 16,404 non-médailles
- **Probabilité moyenne médaillés** : 57.6%
- **Probabilité moyenne non-médailles** : 14.1%

Top 100 Athlètes Prometteurs

Probabilité cumulée : 59.98 médailles

- USA : 22 athlètes
- Australie : 37 athlètes
- France : 16 athlètes

WebApp et API en Production

Interface Web (5 Pages)

01

Accueil

Dashboard avec statistiques temps réel et navigation intuitive

02

Exploration

Base de données complète : 11,110 athlètes avec filtres avancés

03

Prédictions XGBoost

Résultats détaillés par pays, sport et athlète individuel

04

Visualisations

Graphiques interactifs Plotly pour analyses visuelles

05

Analyses Avancées

Comparaisons historiques et projections détaillées

API REST (8 Endpoints)

```
GET /api/data/countries
GET /api/data/sports
GET /api/search/athletes
GET /api/charts/predictions_*
GET /api/predictions/country
GET /api/predictions/athlete
GET /api/stats/global
GET /api/stats/historical
```

Performance Optimale


<50ms

Temps de réponse par
requête

8.6KB

Taille cache prédictions

Comparaison des Versions



Évolution Technique Détaillée

Métrique	M1 (RF)	M2 (CB)	M3 (XGB)
Médailles France	34	28	58
ROC-AUC	~80%	~84%	90.6%
Features	7	7	12
Algorithme	RF 100	GB 100	XGB 250
Calibration	Pondérée	Pondérée	Intelligente

Facteurs de Succès V3

- 1 Données réelles athlètes qualifiés 2024
- 2 Feature engineering sophistiqué avec 5 nouvelles variables
- 3 XGBoost supérieur au Random Forest
- 4 Calibration par taille des délégations

Conclusion et Perspectives

Objectifs Atteints



Questions Olympiques

3 problématiques majeures résolues avec précision grâce à l'IA



Performance Exceptionnelle

ROC-AUC 90.6% dépassant les standards d'excellence



Application Complète

WebApp fonctionnelle + API RESTful professionnelle



Pipeline Industriel

Chaîne complète : nettoyage → entraînement → prédiction

Résultats Clés

58

Médailles France

Prédiction réaliste pour le pays hôte

11K

Athlètes Analysés

Profils individuels complets

1,044

Médailles Totales

Répartition sur 122 pays

Perspectives Futures

1. **Modèles Ensemble** : Combinaison XGBoost + CatBoost + Random Forest
2. **Dashboard Temps Réel** : Suivi live pendant les JO avec mise à jour continue
3. **Apprentissage Continu** : Amélioration automatique avec résultats réels
4. **Deep Learning V4** : Réseaux de neurones pour version future

 **Impact du projet** : Nous avons développé un système prédictif olympique de référence avec une méthodologie rigoureuse, reproductible et scientifiquement validée, ouvrant la voie à de futures applications en analyse sportive prédictive.